Angewandte Bioinformatik

20. Mai 2026, SS 2026

Aufgabe 4.1

Es wird folgendes Experiment betrachtet: Reispflanzen wurden mit 2 Bakterienstämmen von Xanthomonas-Bakterien infiziert. Es wurden RNA-Seq Daten für die infizierten- und mit einer Kontroll-Behandlung behandelten Pflanzen erhoben. Diese Daten sollten aus dem NCBI Sequence Read Archive unter der Accsession PRJNA280380 heruntergeladen werden. Nun sollte eine Qualitätskontrolle der Daten mittels FastQC vorgenommen und die Beobachtungen daraus für die einzelnen Kategorien beschrieben werden. FastQC kann Probleme, in den vorliegenden Transkripten vor der Sequenzierung bereits da waren, oder jene, die durch die Sequenzierung entstanden sind erkennen.

Zunächst kann man allgemein sagen, dass FastQC die Qualitätskontrolle in verschiedene Kategorien aufgliedert. Die Kategorien betrachten jeweils für die Beurteilung der Qualität der RNA-Seq-Daten des Experiments wichtige Aspekte, Informationen bzw. Statistiken über Daten.

Außerdem gibt FastQC zu jeder Kategorie eine Bewertung ab. Diese zeigt auf, ob ein möglicher Qualitätsmangel besteht und wenn ja dessen Schweregrad. Dazu gibt es die 3 Bewertungslevel: Normal, „Warning“ und „Failure“. Bei der Bewertung „Failure“ ist ein deutlicher Qualitätsmangel wahrscheinlich. Bei „Warning“ könnte ein leichterer Qualitätsmangel bestehen. Es sollte allerdings abhängig von der Kategorie stets geprüft werden, ob unter Berücksichtigung der speziellen Hintergrundinformationen zum Experiment ein tatsächlicher Qualitätsmangel besteht. Qualitätsmängel können zum einen durch Durchführung des Experiments, aber auch durch Trimmen der Sequenzen oder Adapter-Entfernung behoben bzw. gemildert werden.

Kurze Beschreibung der Beobachtungen zu den einzelnen Kriterien:

Basic Statistics

In dieser Kategorie stellt FastQC nie Qualitätsmängel fest. Die angegebenen Grundlegenden Informationen sind allerdings trotzdem nützlich: Die vom Sequenziergerät angegebenen Qualitätsscores pro Sequenzposition und Read (im FastQ-File) sind im Illumina 1.9 Format. Es wird allerdings in der FastQC-Dokumentation darauf hingewiesen, dass FastQC das Encoding-Format in seltenen Fällen möglicherweise falsch bestimmt haben könnte.

Weitere Parameter, wie die Gesamtzahl der Reads, die Readlänge und der Gesamt-GC-Gehalt können Experiment-spezifisch auf Angemessenheit beurteilt werden. Die Readlänge wurde wahrscheinlich speziell für das Experiment so gewählt.

Per base sequence quality

Es werden Box-Plots und der Mean der Verteilung der Qualitätsscores für jede Position der Reads dargestellt. Abbildung zeigt, dass die Scores der meisten Sequenzen generell sehr hoch sind. Daher ist die Bewertung von FastQC hier „unauffällig“. Die Scores sind normalerweise im Intervall [0,40]. Die Fehlerwahrscheinlichkeit

beträgt für einen Score von 30 nur 0,1%.

Man sieht im Allgemeinen eine leichte Verschlechterung der Scores an den Enden der Reads, wobei die Qualität ganz am hinteren Ende für einen signifikanten Anteil ziemlich schlecht wird. Dieser ist allerdings zu klein damit FastQC hier eine Warnung auslösen würde Bei der standardmäßigen Sequenzierung mit Illumina ist eine Verschlechterung der Qualität zum Ende hin normal.

Per Tile Sequence Quality

Die Grafik (Illumina-Spezifisch) zeigt Abweichungen der Sequenzierqualität je nach Abschnitt auf der Illumina-Flowcell pro Sequenzposition von der mittleren Qualität pro Abschnitt. Man sieht, dass es so gut wie keine generelle Unterschiede (wenn bessere Qualität als im Mittel) zwischen den Flowcell-Abschnitten gibt, was von hoher Qualität zeugt. Daher wird hier auch mit „unauffällig“ bewertet.

Per sequence quality scores

Die dargestellte Verteilung der Scores der Reads zeigt, dass fast alle Reads einen hohen Gesamtscore haben. Dies zeigt auch die Bewertung von FastQC.

Per base sequence content

Die Abbildung zeigt die Verteilung jeder Base einzeln über die Positionen. Nur bis zu Position 13 Schwanken die Gehalte stark bzw. auffällig. FastQC geht von einer zufälligen Verteilung der Basen aus und erwartet daher uniforme Verteilungen mit kaum Abweichungen zwischen diesen, diese Annahme trifft auf Sequenzierdaten guter Qualität i. d. R. zu. An Position 7 gibt es eine Abweichung des A- und T-Gehalts von über 20% was mit den starken Schwankungen an Positionen am Anfang auf bestimmte Primer- oder Adapter-Sequenzen am Anfang der Reads hindeuten, welche nicht zu den Transkript-Sequenzen gehören und daher herausgefiltert werden müssten.

Per sequence GC content

Die dargestellte GC-Verteilung über die Sequenzpositionen weicht stark von der von FastQC erwarteten Normalverteilung ab. Die empirische Verteilung weist deutlich weniger Varianz als die erwartete, allerdings mit deutlich mehr Sequenzen mit höherem GC-Anteil als im Mittel als erwartet (keine unimodale Verteilung). Durch diese Abweichungen ist die FastQC-Bewertung: „Failure“. Der Grund für diese Abweichungen könnten überrepräsentierte Sequenzen, wie besonders stark exprimierte Gene, aber möglicherweise auch nicht erwünschte Sequenzen (Verunreinigungen) sein. Hier müsste genauer geprüft werden, ob ein tatsächlicher Mangel besteht.

Per base N content

Es gibt kaum Basen über die gesamten Reads, die in der Sequenzierung nicht identifiziert werden konnten (als „N“ markiert). Dies ist angemessen.

Sequence Length Distribution

Alle Basen haben dieselbe Länge, was optimal ist.

Sequence Duplication Levels

Es ist die Verteilung von Duplikationszahlen von Sequenzen dargestellt. Es sind über 50% der Sequenzen in den Reads Duplikate, daher bewertet FastQC mit „Failure“. Eine solch hohe Zahl an Duplikaten kann auf eine geringe Komplexität der Ausgangssequenz-Library hinweisen, außerdem könnten die Duplikate durch Adapter oder PCR-Duplikate zustande kommen. Wichtig ist, dass FastQC bei der Duplikatermittlung Sequenzen, die länger als 75 bps sind auf 50 bps kürzt. Allerdings ist bei (Transkriptom) RNA-Seq Daten gewisse Duplikate zu erwarten durch stark exprimierte Transkripte, im Gegensatz zu genomischen Sequenzen. Allerdings könnte eine gewisse Zahl an Duplikaten auch unerwünscht sein. Ungewöhnlich ist, dass es eine Sequenz gibt, über 10000-mal dupliziert vorliegt, dies könnte tatsächlich ein Artefakt sein.

Overrepresented sequences

Es werden überrepräsentierte Sequenzen dargestellt, hier sieht man dass es Adaptersequenzen gibt, die sehr häufig vorkommen. Ein Adapter kommt mit über 50% der Fälle vor, was die gerade beobachteten hohen Sequenz-Duplikationslevel erklärt. Der „TrueSeq“-Adapter kommt von dem sog. „Illumina TruSeq library prep kit“. Diese Teilsequenzen sollten entfernt werden. Eigentlich sollte FastQC hier auch eine „Failure“ Bewertung abgeben.

Adapter Content

FastQC listet hier die Häufigkeit der Vorkommen von häufig genutzten Adaptern in den Reads auf. Man sieht, dass die Kontamination mit diesen sehr gering ist, was gut ist.