Angewandte Bioinformatik

10. Juni 2026, SS 2026

Aufgabe 6.2

Bedeutung folgender Gütemaße:

a) Sensitivität

Die Sensitivität ist (für 2-Klassen-Probleme) definiert als:

$$\text{Sensitivität} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

Sie beschreibt wie hoch die Wahrscheinlichkeit eines Klassifikators in einem Datensatz ist, Datenpunkte, für welche die Klasse positiv ausgeprägt ist, korrekt unter den positiven zu klassifizieren.

TP ist die Anzahl der korrekt klassifizierten Datenpunkte mit positiver Ausprägung der Klasse und FN die Anzahl der falsch klassifizierten Datenpunkte mit positiver Ausprägung der Klasse.

Die Sensitivität spielt z. B. in der Medizin eine wichtige Rolle bei Tests auf Krankheiten, und beschreibt hier, wie gut der Test Kranke auch wirklich als solche erkennt.

b) Falsch-Positiv-Rate (FPR)

Die FPR ist (für 2-Klassen-Probleme) definiert als:

$$\text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}} = 1 - \text{Spezifität}$$

Die FPR ist ähnlich zur Spezifität, sie ist deren Gegenwahrscheinlichkeit. Damit gibt sie an, wie häufig ein Klassifikator unter der Grundgesamtheit der Datenpunkte mit negativer Ausprägung der Klasse eines Datensatzes dennoch ein Falsch-Positives Ergebnis liefert.

FP sind also die Anzahl der Datenpunkte, die die Eigenschaft der Klasse nicht aufweisen, die vom Klassifikator aber falsch klassifiziert werden. TN ist der Rest unter diesen Datenpunkten, als davon korrekt klassifizierte.

Wegen seiner Definition hat die FPR eine ähnliche Aussage zur Spezifität, außerdem wird sie für die Erstellung von Receiver-Operating-Curves (ROC-Curves) verwendet. Diese Kurven sind ein klassisches Maß zur Beurteilung von Klassifikatoren. Die ROC-Curve ist die True-Positive-Rate (TPR) bzw. Sensitivität/Recall in Abhängigkeit von der FPR.

c) Spezifität

Die Spezifität ist (für 2-Klassen-Probleme) definiert als:

$$\text{Spezifität} = \frac{\text{TN}}{\text{TN} + \text{FP}}$$

Sie misst, im Gegensatz zur Sensitivität, mit welcher Wahrscheinlichkeit ein Klassifikator Datenpunkte in einem Datensatz unter der Grundgesamtheit aller Datenpunkte mit negativer Ausprägung korrekt als solche klassifizieren kann. In der Medizin ergänzt die Spezifität die Sensitivität als zentrales Maß zur Beurteilung von diagnostischen Tests. Hier beschreibt sie, wie häufig ein Test bei gesunder Person auch ein richtiges Ergebnis liefert.

d) Precision

Die Precision ist (für 2-Klassen-Probleme) definiert als:

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

Die Precision gibt an, wie viele unter allen von einem Klassifikator als positiv hinsichtlich der Eigenschaft der Klasse ausgewählten Datenpunkte eines Datensatzes auch korrekt sind.

Die Precision ist wichtig für die Bestimmung von Precison-Recall-Curves (PRC), die eine wichtige Alternative zur ROC-Curve für die Bewertung von Klassifikatoren ist. Sie gibt die Precision in Abhängigkeit des Recalls an. Die PRC ist bei unbalancierten Klassifikationsproblemen, wie z. B. der Erkennung von Differenziell Exprimierten Genen ein besseres Maß als die ROC-Curve. Der Grund ist, dass die FPR bei diesen Problemen, den Klassifikator nicht so gut bewerten kann, da diese auch für einen schlechten Klassifikator gering sein kann, da TN»FP. Precision und Recall betrachten die TN nicht.