Angewandte Bioinformatik

18. Juni 2026, SS 2026

Aufgabe 1

a)

Siehe `data_vis.R` und `data_vis_plots` directory.

b)

Auswahl zweier Klassifikationsmodelle zur Lösung des Klassifikationsproblems auf Basis der Visualisierungen der Daten:

Generelle Begründung:
Der Datensatz ist relativ klein und hat eine verhältnismäßig hohe Dimensionalität. Daher sollten keine zu komplexen Modelle oder jene, welche viele Trainingsdaten benötigen, gewählt werden. Daher fällt die Wahl zunächst gegen Neuronale Netze. Außerdem eignen sich der Gaussian Naive Bayes Klassifikator nicht, da die Daten nicht Gaussverteilt und die einzelnen Merkmale nicht unabhängig voneinander sind. Aufgrund der wenigen Trainingsdaten, ist ein einfacher Entscheidungsbaum, aufgrund der Anfälligkeit für Overfitting ungeeignet.

1. Random Forest:
Begründung: Da die Daten hohe Dimensionalität haben und die Features scheinbar korelliert sind, wäre ein Entscheidungsbaum möglicherweise gut geeignet. Um das Overfitting zu reduzieren, wählen wir einen Random Forest. Er sollte noch besser mit gegen Overfitting gerüstet sein, als Gradient Boosting.

2. Support Vector Machine (SVM):
Begründung: Die Daten sind in vielen Dimensionen zu einem großen Teil linear separierbar. Eine SVM kann dies gut modellieren und umgeht das Problem des Overfitting in höheren Dimensionen gut.

c)

Siehe `svm.py` und `randomForest.py` und für die Protokolle `svm_cv.json` und `rf_cv.json`.

d)

Die SVM wurde auf dem Trainingsdatensatz trainiert und auf dem Testdatensatz evaluiert, da diese in der Cross-Validation den besten Mittleren ROC-AUC-Score erhielt.

Siehe `test_svm.py` und `predictions_aufg_1.txt`