Angewandte Bioinformatik

25. Juni 2026, SS 2026

Aufgabe 9.2

a)

Siehe `detect_ol_cds.py`.

b)

Siehe `load_genome_detect_ol_cds.sh`.

c)

Ausgabe siehe `script_out.txt`. Es werden zusätzlich zu Sequenz-Positionen der überlappenden Sequenzen auch deren Größe ausgegeben. Außerdem wird die Verteilung der Überlappungsgrößen visualisiert.

Es werden nur Überlappungen auf dem gleichen Strang gesucht.

Interpretation der Verteilung der Überlappungsgrößen:

Die verhältnismäßig viel größere Zahl von sehr kurzen Overlaps (vor allem 2 u. 5 Nukleotide) gegenüber längeren Überlappungen könnte auf die Überlappungen von Start- und Stop-Codons hindeuten. Wenn diese gleiche Nukleotide aufweisen, so können Coding Sequences im Genom dicht aneinander gereiht werden.

Dies ist eine häufig gemachte Beobachtung in Genomen von Prokaryoten. Diese werden als Gen-Dicht beschrieben[1]. Außerdem sind funktional ähnliche Gene of nah beisammen, Prokaryotische Gene sind in Operons organisiert. Gene in einem Operon sind translational-gekoppelt, d. h. die Expression eines Gens verstärkt auch die Expression eines benachbarten Gens.

Ein weiterer Grund für die geringe Zahl größerer Überlappungen könnte sein, dass durch große Überlappungen der Sequenzen, eine starke Reglementierung von deren Funktionalität als synthetisierte Proteine darstellt und außerdem Mutationen beide Proteinsequenzen erfasst.

[1] `https://doi.org/10.1128/jb.00255-25`